Aplicação de Técnicas de Machine Learning na Identificação de Municípios do Nordeste Brasileiro com Maior Potencial para Atração de Investimentos a Partir de Dados Socioeconômicos

Aluno: Arthur Lins da Gama
Orientador: Guilherme Fernando Cavalcanti Pereira
Dezembro/2025

Roteiro

Desenvolvimento e Resultados

Regressão
Classificação
Análise dos Resultados

Fase preliminar

Introdução
Justificativa
Problema de Pesquisa
Objetivos
Metodologia

Finalização

Conclusão
Trabalhos Futuros

Introdução

- Decisões estratégicas baseadas em dados.
- O destaque do Machine Learning na capacidade de identificar padrões complexos e gerar previsões precisas a partir de grande volumes de informações
- Nordeste Brasileiro pouco explorado em modelos preditivos.
- Dificuldade em identificar municípios com alto potencial de investimento
- Aplicação de ML em dados socioeconômicos do Nordeste.

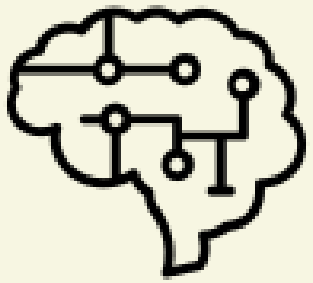

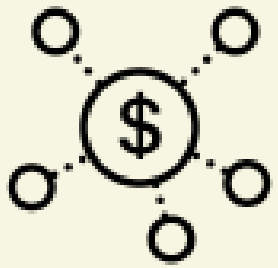

Justificativa

Relevância Socioeconômica

Inovação Metodológica

Valor Prático e Aplicação

Problema de Pesquisa

Quais são os principais determinantes socioeconômicos que explicam o potencial de investimento dos municípios do Nordeste? E como modelos de Machine Learning podem utilizar esses fatores para prever e classificar os municípios mais promissores?

Objetivos

Objetivo Geral

Avaliar e comparar modelos de ML capazes de identificar municípios do Nordeste brasileiro com maior potencial de atração de investimentos, utilizando dados socioeconômicos, setoriais e geográficos.

Objetivos Específicos

1. Realizar o levantamento, tratamento e organização de uma base de dados socioeconômicos, fiscais e demográficos dos municípios do Nordeste.
2. Aplicar e comparar algoritmos de Machine Learning para duas abordagens:

- **Regressão:** Para prever o valor do potencial de investimento (proxy: PIB per capita).
- **Classificação:** Para classificar os municípios em faixas de potencial.

3. Interpretar os fatores determinantes (importância das variáveis) que mais influenciam o potencial de investimento e validar o modelo de melhor performance gerando um ranking dos municípios mais promissores para a tomada de decisão, e visualizando a estabilidade temporal dos municípios classificados como alta oportunidade.

Fundamentação Teórica

Desigualdades Estruturais no Nordeste

“O desenvolvimento do Nordeste é marcado por desigualdades estruturais e por padrões espaciais persistentes ao longo do tempo.” — Hissa-Teixeira (2018)

“A estrutura produtiva municipal (indústria, serviços e formalização do trabalho) é determinante para explicar o potencial econômico.” — Antunes (2024)

Por que Machine Learning?

“Modelos baseados em árvores capturam relações não lineares complexas que os métodos estatísticos tradicionais não conseguem identificar.” — Breiman (2001)

“O XGBoost é um método de boosting eficaz para dados tabulares, oferecendo alta performance e interpretabilidade em problemas reais.” — Chen & Guestrin (2016)

Metodologia

Coleta e Tratamento de Dados (ETL)

Análise Exploratória dos Dados (EDA)

Modelagem Estatística e de Machine Learning

Análise dos Resultados

ETL

Fontes: IBGE para dados como PIB, População e Área Territorial; Tesouro Transparente para dados fiscais de Receitas e Despesas Municipais (FINBRA) ; RAIS para dados de Vínculo de Emprego Formal

- Engenharia de Variáveis (Normalização por Razão)
- Tratamento Matemático
- Imputação de Dados
- Remoção de Viés
- Seleção Final de Features

EDA

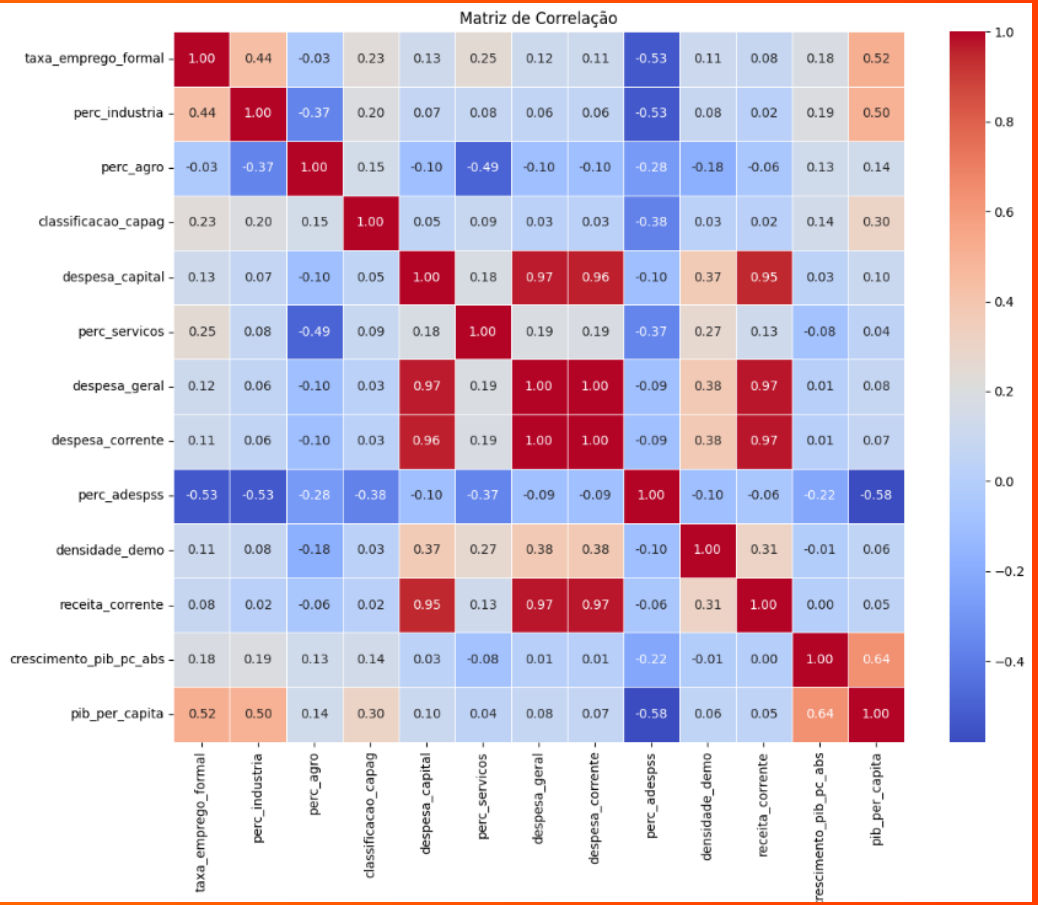

Modelos Estatísticos e de Machine Learning (Regressão)

Comparação e Seleção do Modelo Preditivo Final

Model	R^2	RMSE	MAE	MAPE (%)
Linear Regression (Nordeste)	0.761137	0.225915	0.157966	6.103624
Random Forest (Nordeste)	0.862062	0.171063	0.127406	4.987552
XGBoost (Nordeste)	0.882309	0.158010	0.117689	4.610549

Importância das variáveis - XGBoost

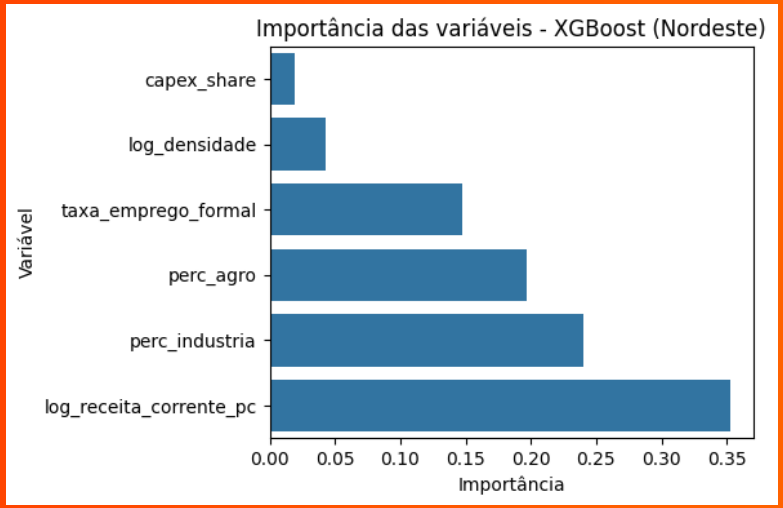

Ranking

Top 10 Municípios do Nordeste por Potencial Previsto (2021)

	municipio	uf	pib_per_capita	pib_pc_previsto	taxa_emprego_formal	perc_industria	perc_agro	log_receita_corrente_pc
4718	Godofredo Viana	MA	219.637670	207.097458	0.132683	0.830908	0.003956	8.620553
4597	Santo Antônio dos Lopes	MA	210.483640	202.387024	0.090521	0.932851	0.005733	8.586532
14732	São Bento do Norte	RN	204.331473	193.071777	0.321920	0.887423	0.020709	9.613488
1149	Formosa do Rio Preto	BA	176.485026	165.812805	0.101834	0.032807	0.765274	8.034662
2655	São Gonçalo do Amarante	CE	175.099621	160.109558	0.284529	0.743105	0.006729	9.236434
863	Jaborandi	BA	164.387550	156.810089	0.228718	0.059158	0.778284	8.558623
13506	Baixa Grande do Ribeiro	PI	150.491746	149.475128	0.231895	0.046596	0.756417	7.751331
12880	Ipojuca	PE	150.646263	147.988281	0.295153	0.605908	0.016258	9.517309
14766	Bodó	RN	131.940608	130.076935	0.146476	0.867133	0.014378	7.939150
4551	Tasso Fragoso	MA	272.064330	129.647125	0.197871	0.029602	0.811131	7.472711

Análise Espacial – PIB per capita
Real x Previsto

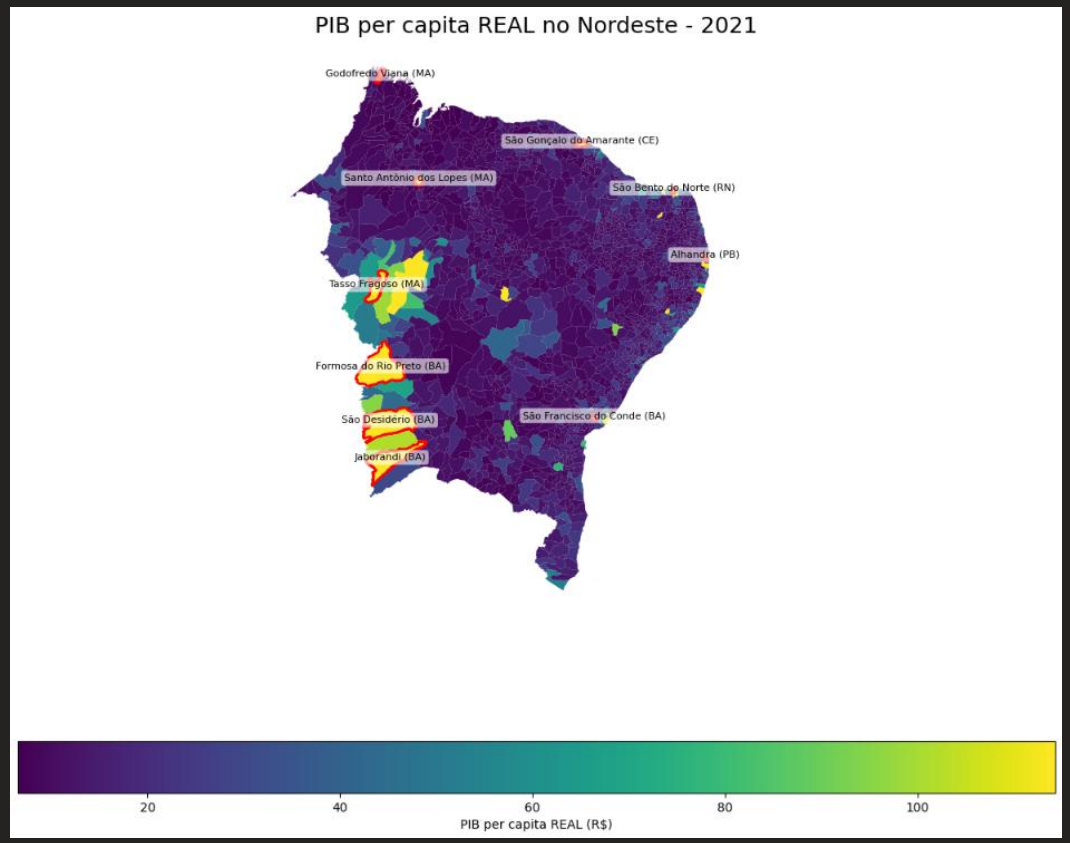

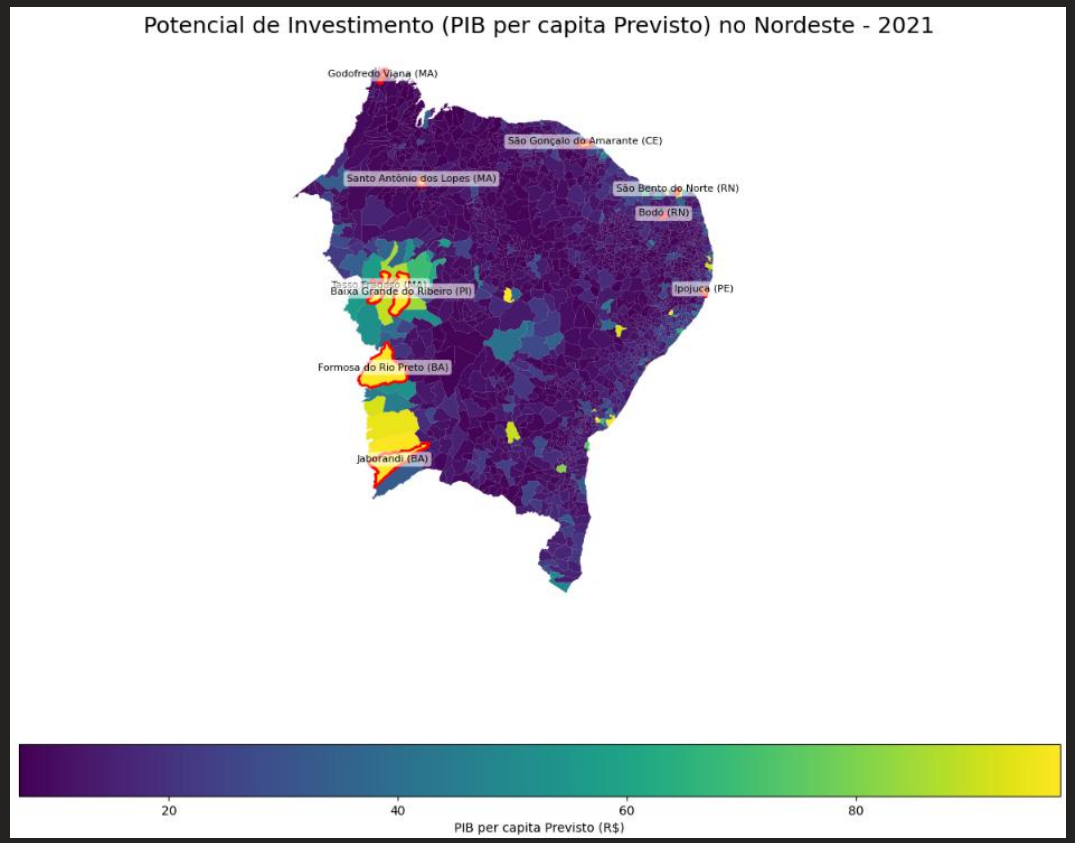

Classificação Binária e Estabilidade Temporal

Comparativo de desempenho dos modelos de classificação

Modelo	Acurácia	Precisão	Recall	F1-score
XGBoost	0.918467	0.876056	0.809896	0.841678
Random Forest	0.910801	0.857542	0.799479	0.827493
Logistic Regression	0.892683	0.873377	0.700521	0.777457

	Ano	Acurácia	Precisão (classe 1)	Recall (classe 1)	F1-score (classe 1)	VP	FP	FN	VN
0	2018	0.942	0.884	0.884	0.884	397	52	52	1292
1	2019	0.952	0.904	0.904	0.904	406	43	43	1301
2	2020	0.951	0.902	0.902	0.902	405	44	44	1300
3	2021	0.961	0.922	0.922	0.922	414	35	35	1309

Comparação da Distribuição de Estabilidade (Real vs. Previsto, 2018-2021)

Categoria de Estabilidade	Distribuição Real (%)	Distribuição Prevista pelo Modelo (%)
Nunca alta oportunidade	69,6%	68,4%
Sempre alta oportunidade	20,0%	19,3%
Instável	10,4%	12,3%

- Nunca alta oportunidade: Municípios que nunca estiveram no quartil superior (P75) no período.
- Sempre alta oportunidade: Municípios que estiveram no quartil superior (P75) em todos os anos.
- Instável: Municípios que flutuaram, entrando ou saindo da categoria "Alta Oportunidade".

Análise Espacial – Estabilidade temporal

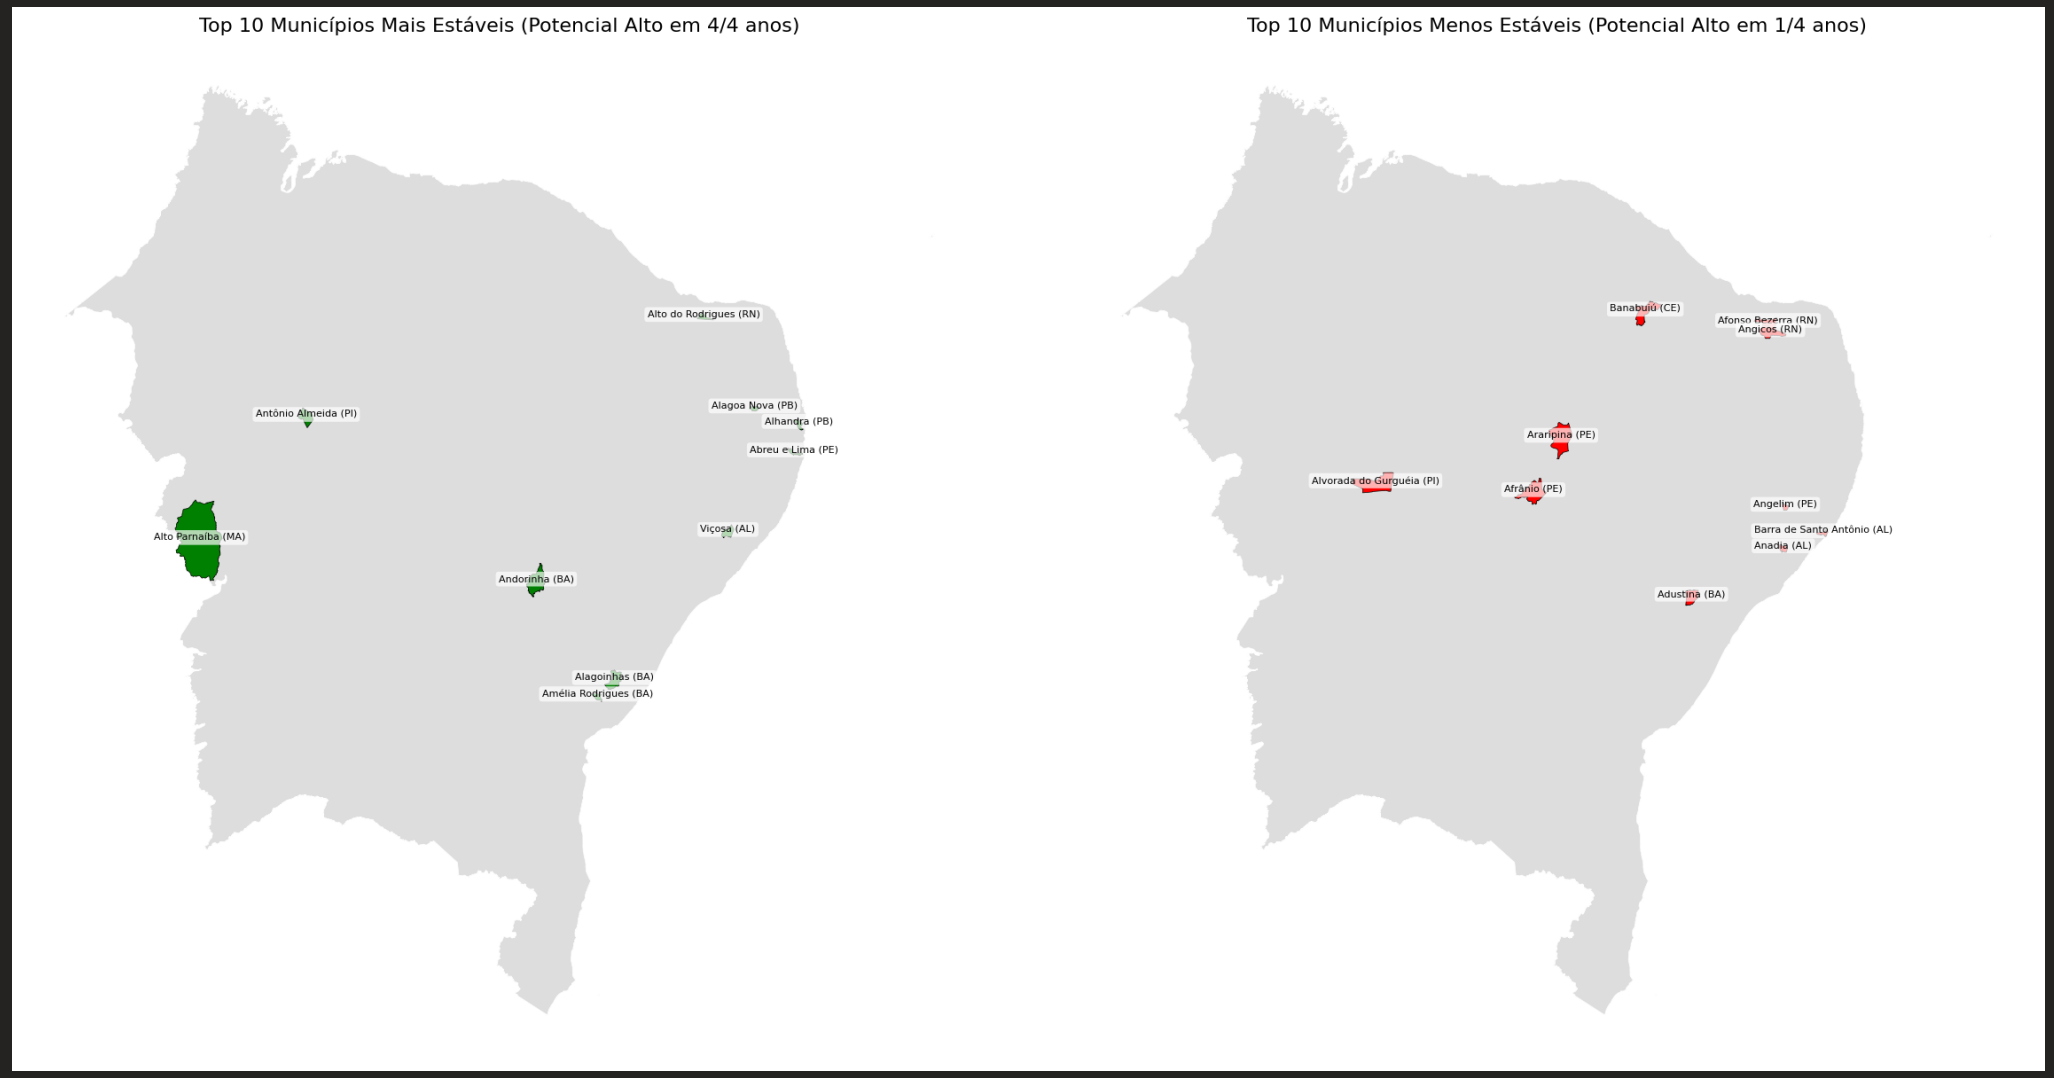

Análise dos Resultados

Implicações Metodológicas — Superioridade Não Linear

- OLS é insuficiente para a complexidade regional do Nordeste.
- XGBoost captura interações não lineares ($R^2 = 0.882$).
- ML recupera 12 pontos percentuais de variância ignorada pelo modelo linear.
- O XGBoost solucionou o paradoxo, e entendeu que o investimento é complexo e não imediato.

Implicações Econômicas — Motores do Potencial

- Principais determinantes:
  - log_receita_corrente_pc
  - taxa_emprego_formal
  - perc_industria / perc_agro
- Indicadores puramente fiscais ou estáticos (como a nota CAPAG) mostraram menos relevância do que a estrutura produtiva.
- Ranking confirma polos industriais, de energia e mineração como municípios de maior potencial.

Análise dos Resultados

Implicações Espaciais — Desigualdades Estruturais

- O mapa (Real vs. Previsto) desenhou corretamente o litoral rico e as "ilhas" de riqueza no interior (Petrolina-Juazeiro, Oeste Baiano)
- Os dados de estabilidade (2018-2021)
  - ~20% “Sempre Alta”
  - ~70% “Nunca Alta”

Aplicações Práticas

- Investidor privado
- Gestor público

Conclusão

- Eficácia do ML
- Desigualdade Estrutural
- Diagnóstico Robusto
- Instrumentos Aplicaveis
- Inteligência de Decisão
- Metodologia Replicável

Trabalhos Futuros

- Incorporar novas variáveis e trazer dados mais atualizados.
- Trazer outros modelos de ML mais avançados e comparações.
- Dashboard interativo para um sistema de monitoramento contínuo, permitindo visualizar os rankings, mapas e indicadores em tempo real.

OBRIGADO!

ALG2@CESAR.SCHOOL
GAMAARTHUR08@GMAIL.COM

C.E.S.A.R school